Algorytm SVM

Maciej Kusy

Katedra Podstaw Elektroniki

Spis treści

- Wstęp
- Wymiar Vapnika-Chervonenkisa
- Problem liniowo separowalny
- Problem nieliniowo: C-SVM
- Podejście ν-SVM
- SVM w klasyfikacji jednoklasowej
- Klasyfikacja na wiele klas
- Prawdopodobieństwo klas
- Implementacje SVM
- Realizacja SVM: algorytm SMO
- Literatura

Algorytm SVM

SVM (ang. *support vector machine*) to metoda uczenia nadzorowanego wywodząca się ze statystycznej teorii uczenia.

Stosowana jest m.in. do[1]:

- **klasyfikacji**, w podstawowej postaci binarnej (Cortes, 1995),
- regresji (Drucker et al., 1997).

Założenie: dobre dopasowanie klasyfikatora do danych uczących nie gwarantuje małego błędu dla nowych obserwacji.

Dlatego w SVM uwzględnia się jego złożoność; realizowane to jest zgodnie z ideą minimalizacji ryzyka strukturalnego (SRM).

Jedną z teoretycznych miar złożoności rodziny klasyfikatorów jest **wymiar VC**.

[1] Uwaga: również do klasteryzacji

Wymiar Vapnika-Chervonenkisa

Wymiar VC jest miarą złożoności rodziny klasyfikatorów binarnych (Vapnik i Chervonenkis, 1971).

Rozważamy L punktów o ustalonych położeniach. Każdemu przypisujemy etykietę -1 lub 1. Istnieje 2^L możliwych przypisań etykiet.

Rodzina klasyfikatorów **rozbija** ten zbiór, jeśli dla **każdego** przypisania etykiet istnieje klasyfikator z tej rodziny, który klasyfikuje wszystkie punkty bez błędów.

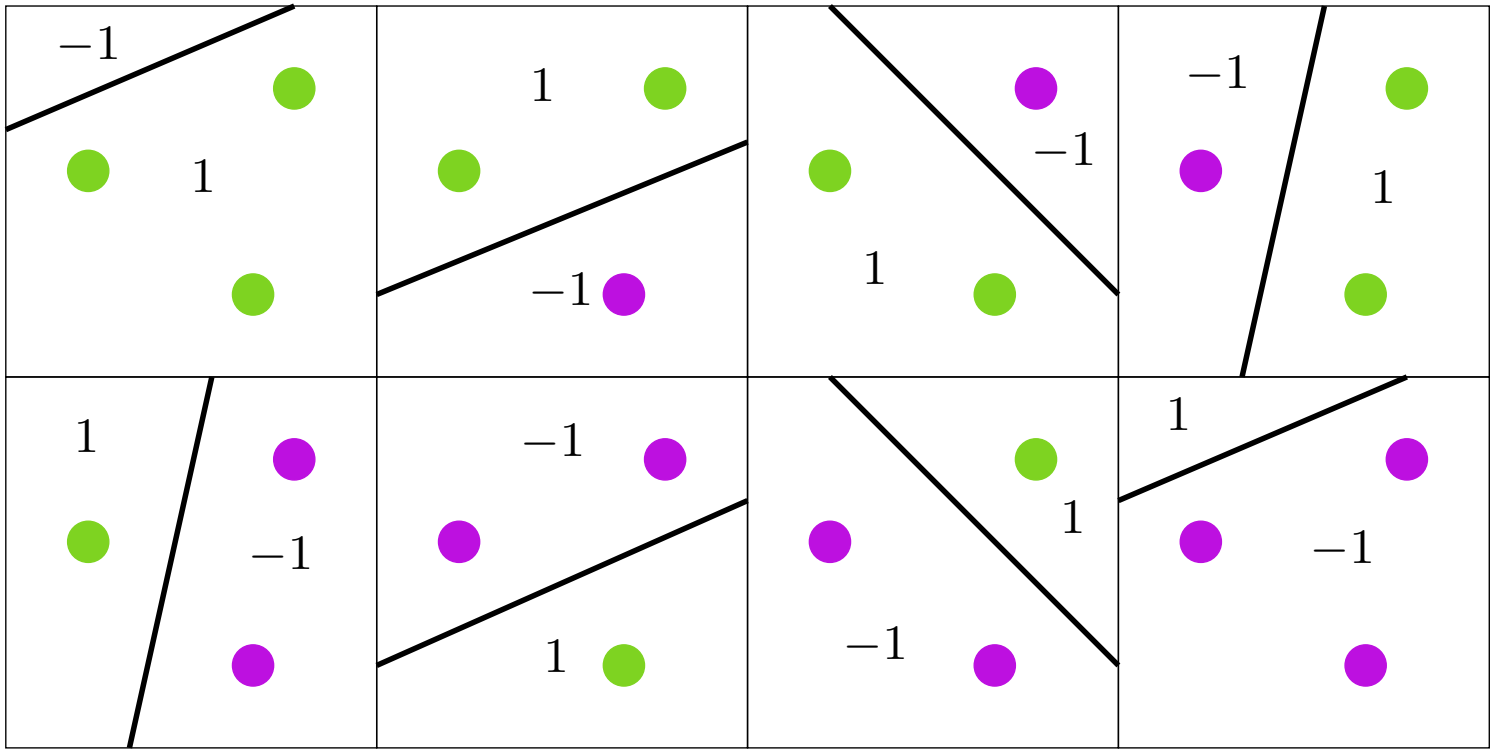
Dla każdego przypisania można dobierać **inne parametry klasyfikatora**.

Definicja wymiaru VC

Wymiar VC to największa liczba punktów, dla której **istnieje zbiór rozbijany** przez rozważaną rodzinę klasyfikatorów. Jeśli można rozbijać dowolnie duże zbiory, wymiar VC jest nieskończony.

Wymiar VC: swoboda przypisania etykiet

Rozważamy $L = 3$ niewspółliniowe punkty na płaszczyźnie. Istnieje $2^3 = 8$ możliwych przypisań etykiet dwóch klas.



Dla każdego przypisania istnieje prosta, która klasyfikuje wszystkie punkty bez błędów: zbiór jest **rozbijany przez rodzinę klasyfikatorów liniowych.**

Żadnego zbioru 4 **punktów na płaszczyźnie** nie można rozbić za pomocą prostych. Stąd dla tej rodziny klasyfikatorów $VC = 3$.

Problem liniowo separowalny – założenia

Dany jest zbiór uczący:

$$\mathcal{D} = \{(\mathbf{x}_l, y_l)\}_{l=1}^{L}, \tag{1}$$

gdzie:

- $\mathbf{x}_l = (x_{l1}, \ldots, x_{lI})^\top \in \mathbb{R}^I$ - wektor cech l-tej obserwacji,
- $y_l \in \{-1, +1\}$ – etykieta jej klasy.

Zakładamy, że klasy można rozdzielić hiperpłaszczyzną

$$\mathbf{w} \cdot \mathbf{x} + b = 0, \tag{2}$$

gdzie $\mathbf{w} \neq \mathbf{0}$ jest wektorem normalnym do hiperpłaszczyzny, a b jej wyrazem wolnym. Oznacza to, że

$$y_l(\mathbf{w} \cdot \mathbf{x}_l + b) > 0 \quad \text{dla każdego } l = 1, \ldots, L.$$

Liniowa separowalność

Dla liniowo separowalnych danych możemy dobrać $\mathbf{w}$ i b tak, aby najmniejsza wartość $\mathbf{w} \cdot \mathbf{x}_l + b$ w klasie $+1$ wynosiła $+1$, a największa wartość w klasie -1 wynosiła -1:

$$\min_{l:\, y_l=+1} (\mathbf{w} \cdot \mathbf{x}_l + b) = +1, \qquad \max_{l:\, y_l=-1} (\mathbf{w} \cdot \mathbf{x}_l + b) = -1.$$

Wówczas wszystkie punkty uczące spełniają warunek:

$$y_l(\mathbf{w} \cdot \mathbf{x}_l + b) \geqslant 1, \quad l = 1, \ldots, L. \tag{3}$$

Równoważnie:

$$\begin{cases} \mathbf{w} \cdot \mathbf{x}_l + b \geqslant +1 & \text{dla } y_l = +1, \\ \mathbf{w} \cdot \mathbf{x}_l + b \leqslant -1 & \text{dla } y_l = -1. \end{cases} \tag{4}$$

Punkty, dla których zachodzi równość, leżą na granicach pasa i są najbliżej hiperpłaszczyzny separującej w swoich klasach.

Wyznaczanie szerokości pasa między klasami

Odległość punktu $\mathbf{x}$ od hiperpłaszczyzny $H_0 : \mathbf{w} \cdot \mathbf{x} + b = 0$ wynosi:

$$\delta(\mathbf{x}, H_0) = \frac{|\mathbf{w} \cdot \mathbf{x} + b|}{\|\mathbf{w}\|}. \tag{5}$$

Niech $\mathbf{x}_{l_+}$ i $\mathbf{x}_{l_-}$ oznaczają punkty odpowiednich klas najbliższe hiperpłaszczyźnie H_0.

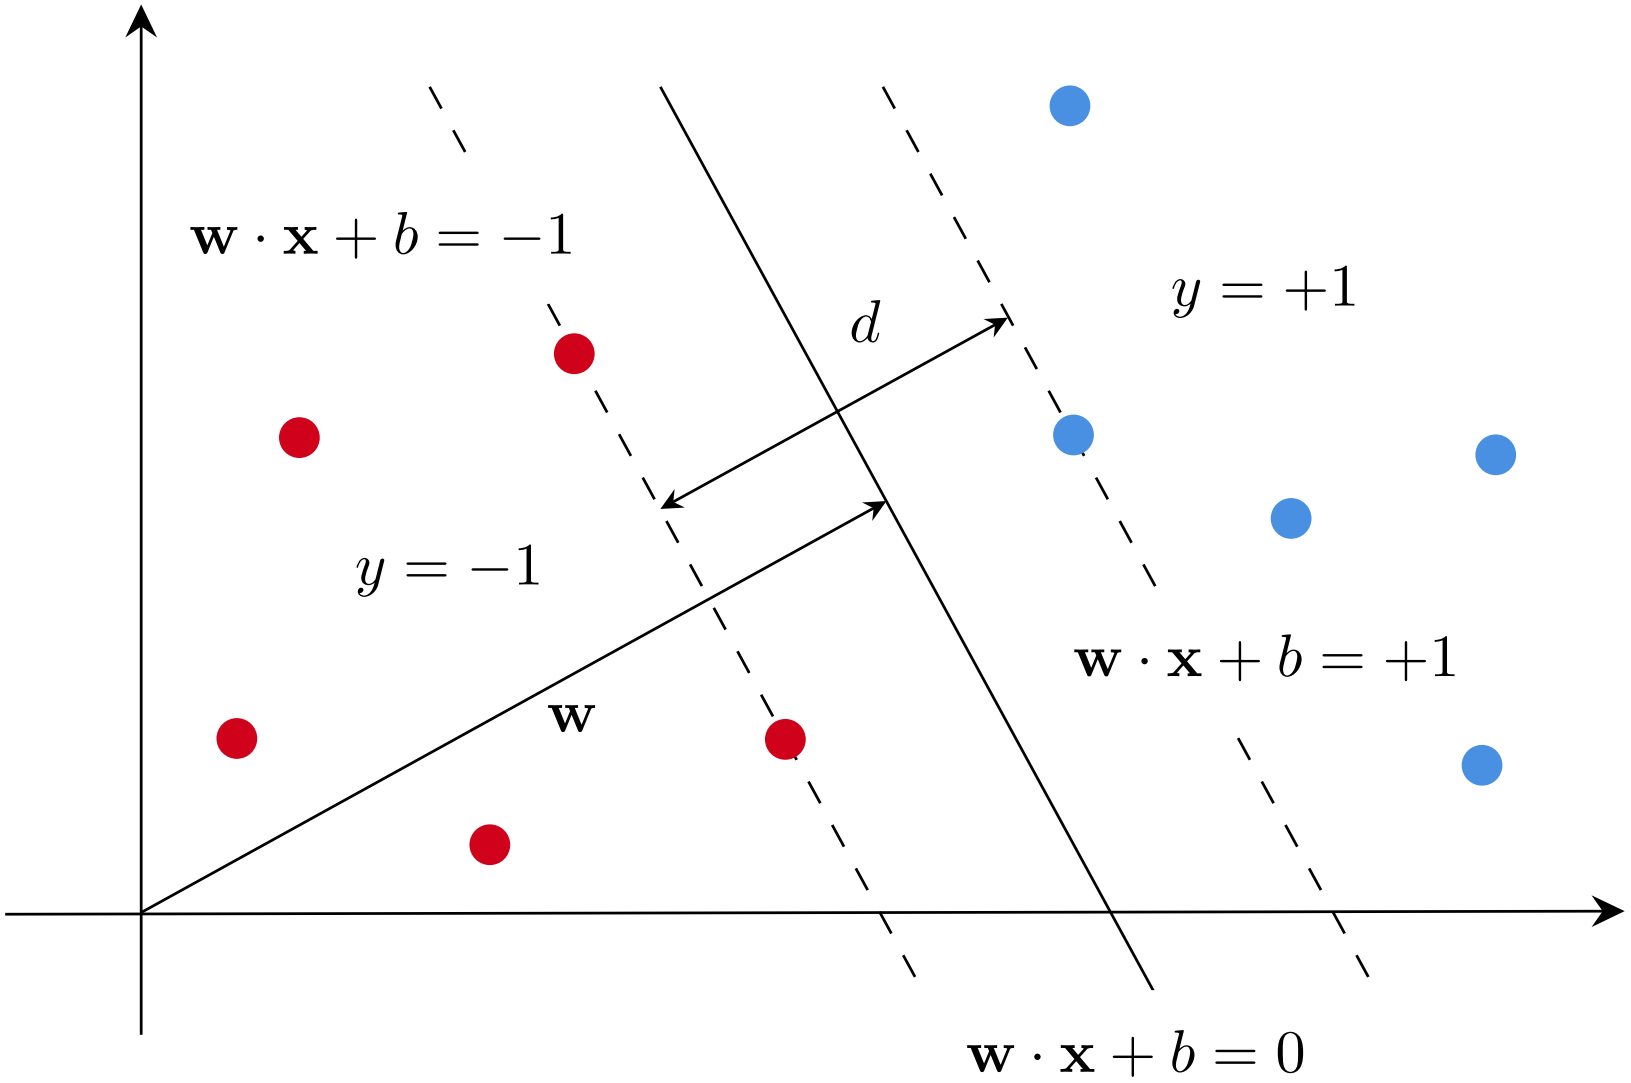
$$d_+ = \min_{l:\, y_l = +1} \delta(\mathbf{x}_l, H_0) = \frac{|\overbrace{\mathbf{w} \cdot \mathbf{x}_{l_+} + b}^{+1}|}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|},$$

$$d_- = \max_{l:\, y_l = -1} \delta(\mathbf{x}_l, H_0) = \frac{|\overbrace{\mathbf{w} \cdot \mathbf{x}_{l_-} + b}^{-1}|}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}.$$

Szerokość pasa wynosi zatem:

$$d = d_+ + d_- = \frac{2}{\|\mathbf{w}\|}. \tag{6}$$

Graficzna interpretacja szerokości pasa d



Optymalna hiperpłaszczyzna separująca

Optymalna hiperpłaszczyzna separująca (ang. *optimal separating hyperplane*, **OSH**) to hiperpłaszczyzna, dla której szerokość pasa między klasami jest największa.

Ponieważ $d = 2/\|\mathbf{w}\|$, maksymalizacja d jest równoważna rozwiązaniu problemu:

$$\begin{aligned} \min_{\mathbf{w},b} \quad & \Phi(\mathbf{w}) = \frac{1}{2}\|\mathbf{w}\|^2, \\ \text{przy warunkach} \quad & y_l(\mathbf{w}\cdot\mathbf{x}_l + b) \geqslant 1, \quad l = 1,\ldots,L. \end{aligned} \tag{7}$$

Jest to **problem podstawowy** (ang. *primal problem*) liniowo separowalnego SVM.

Przejście do problemu dualnego

Każdemu ograniczeniu problemu podstawowego (7) przypisujemy mnożnik Lagrange'a $\alpha_l \geqslant 0$, $l = 1, \ldots, L$.

Lagrangian ma postać:

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\mathbf{w} \cdot \mathbf{w} - \sum_{l=1}^{L} \alpha_l \left[y_l(\mathbf{w} \cdot \mathbf{x}_l + b) - 1 \right]. \tag{8}$$

Dla ustalonych $\boldsymbol{\alpha}$ minimalizujemy Lagrangian względem $\mathbf{w}$ i b, a otrzymaną funkcję maksymalizujemy względem $\boldsymbol{\alpha}$:

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & \min_{\mathbf{w},b} \mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) \\ \text{przy warunkach} \quad & \alpha_l \geqslant 0, \quad l = 1, \ldots, L, \\ & \sum_{l=1}^{L} \alpha_l y_l = 0. \end{aligned} \tag{9}$$

Minimalizacja $\mathcal{L}$ po $\mathbf{w}$

Przy różniczkowaniu po $\mathbf{w}$ mnożniki α_l, etykiety y_l oraz wektory $\mathbf{x}_l$ traktujemy jako stałe.

Ponieważ

$$\nabla_{\mathbf{w}} \left(\frac{1}{2} \mathbf{w} \cdot \mathbf{w} \right) = \mathbf{w}, \qquad \nabla_{\mathbf{w}} (\mathbf{w} \cdot \mathbf{x}_l) = \mathbf{x}_l,$$

otrzymujemy:

$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \mathbf{w} - \sum_{l=1}^{L} \alpha_l y_l \mathbf{x}_l. \tag{10}$$

Warunek stacjonarności $\nabla_{\mathbf{w}} \mathcal{L} = \mathbf{0}$ prowadzi do:

$$\boxed{\mathbf{w} = \sum_{l=1}^{L} \alpha_l y_l \mathbf{x}_l.} \tag{11}$$

Minimalizacja $\mathcal{L}$ po b

Od b zależy tylko część Lagrangianu zawierająca $\mathbf{w} \cdot \mathbf{x}_l + b$. Dlatego:

$$\frac{\partial \mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha})}{\partial b} = -\sum_{l=1}^{L} \alpha_l y_l. \tag{12}$$

Warunek stacjonarności $\frac{\partial \mathcal{L}}{\partial b} = 0$ prowadzi do:

$$\boxed{\sum_{l=1}^{L} \alpha_l y_l = 0.} \tag{13}$$

Jest to warunek, który muszą spełniać mnożniki w problemie dualnym.

Warunki Karusha-Kuhna-Tuckera (KKT)

Dla problemu podstawowego (7) warunki **KKT** mają postać:

$$\begin{cases} \nabla_{\mathbf{w}}\mathcal{L} = \mathbf{w} - \sum_{l=1}^{L} \alpha_l y_l \mathbf{x}_l = \mathbf{0}, \\ \dfrac{\partial \mathcal{L}}{\partial b} = -\sum_{l=1}^{L} \alpha_l y_l = 0, \\ y_l(\mathbf{w}\cdot\mathbf{x}_l + b) - 1 \geqslant 0, \\ \alpha_l \geqslant 0, \\ \alpha_l \left[y_l(\mathbf{w}\cdot\mathbf{x}_l + b) - 1\right] = 0. \end{cases} \tag{14}$$

Trzy ostatnie warunki obowiązują dla każdego $l = 1, \ldots, L$.

Z ostatniego warunku KKT wynika:

$$\alpha_l > 0 \quad \Longrightarrow \quad y_l(\mathbf{w}\cdot\mathbf{x}_l + b) = 1.$$

Rozwinięcie problemu dualnego

Korzystamy z warunków (11) i (13).

Ponieważ $\sum_{l=1}^{L} \alpha_l y_l = 0$, wyraz z b znika. Stąd:

$$
\begin{aligned}
W(\boldsymbol{\alpha}) &= \frac{1}{2}\|\mathbf{w}\|^2 - \mathbf{w} \cdot \sum_{l=1}^{L} \alpha_l y_l \mathbf{x}_l + \sum_{l=1}^{L} \alpha_l \\
&= \sum_{l=1}^{L} \alpha_l - \frac{1}{2}\|\mathbf{w}\|^2 \\
&= \sum_{l=1}^{L} \alpha_l - \frac{1}{2}\left\|\sum_{l=1}^{L} \alpha_l y_l \mathbf{x}_l\right\|^2 \\
&= \sum_{l=1}^{L} \alpha_l - \frac{1}{2}\sum_{l=1}^{L}\sum_{k=1}^{L} \alpha_l \alpha_k y_l y_k (\mathbf{x}_l \cdot \mathbf{x}_k).
\end{aligned}
$$

Ostateczna postać problemu dualnego

Funkcja celu problemu dualnego ma postać:

$$W(\boldsymbol{\alpha}) = \sum_{l=1}^{L} \alpha_l - \frac{1}{2} \sum_{l=1}^{L} \sum_{k=1}^{L} \alpha_l \alpha_k y_l y_k (\mathbf{x}_l \cdot \mathbf{x}_k). \tag{15}$$

Szukamy jej maksimum:

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & W(\boldsymbol{\alpha}) \\ \text{przy warunkach} \quad & \alpha_l \geqslant 0, \quad l = 1, \ldots, L, \\ & \sum_{l=1}^{L} \alpha_l y_l = 0. \end{aligned} \tag{16}$$

Jest to problem programowania kwadratowego (ang. *quadratic programming*, **QP**).

Optymalny klasyfikator

Rozwiązanie problemu dualnego (16) daje mnożniki $\boldsymbol{\alpha}^\star$, a następnie:

$$\mathbf{w}^\star = \sum_{l=1}^{L} \alpha_l^\star y_l \mathbf{x}_l. \tag{17}$$

Niech $\alpha_r^\star > 0$ i $y_r = +1$ oraz $\alpha_s^\star > 0$ i $y_s = -1$. Wówczas

$$\mathbf{w}^\star \cdot \mathbf{x}_r + b^\star = +1, \qquad \mathbf{w}^\star \cdot \mathbf{x}_s + b^\star = -1.$$

Po dodaniu tych równości otrzymujemy:

$$b^\star = -\frac{1}{2}\mathbf{w}^\star \cdot (\mathbf{x}_r + \mathbf{x}_s). \tag{18}$$

Klasyfikator ma zatem postać:

$$\widehat{y}(\mathbf{x}) = \operatorname{sign}\left(\mathbf{w}^\star \cdot \mathbf{x} + b^\star\right). \tag{19}$$

Wektory wspierające

Z ostatniego warunku KKT:

$$\alpha_l^\star \left[y_l(\mathbf{w}^\star \cdot \mathbf{x}_l + b^\star) - 1 \right] = 0 \tag{20}$$

wynika, że:

$$\alpha_l^\star > 0 \quad \Longrightarrow \quad y_l(\mathbf{w}^\star \cdot \mathbf{x}_l + b^\star) = 1. \tag{21}$$

☎ $\mathbf{x}_l$ dla których $\alpha_l^\star > 0$ nazywane są **wektorami wspierającymi** (ang. *support vectors*, SVs).

SVs leżą na granicach pasa, w odległości $1/\|\mathbf{w}^\star\| = d/2$ od OSH gdzie:

$$\mathbf{w}^\star = \sum_{l:\, \alpha_l^\star > 0} \alpha_l^\star y_l \mathbf{x}_l.$$

Punkty z $\alpha_l^\star = 0$ nie są potrzebne do obliczania predykcji po nauczeniu klasyfikatora.

Przykład liniowej separowalności: dane *Iris*

Zbiór *Iris* zawiera 150 obserwacji: po 50 kwiatów z trzech gatunków: *setosa*, *versicolor* i *virginica*.

Każdy kwiat opisano czterema cechami (w cm):

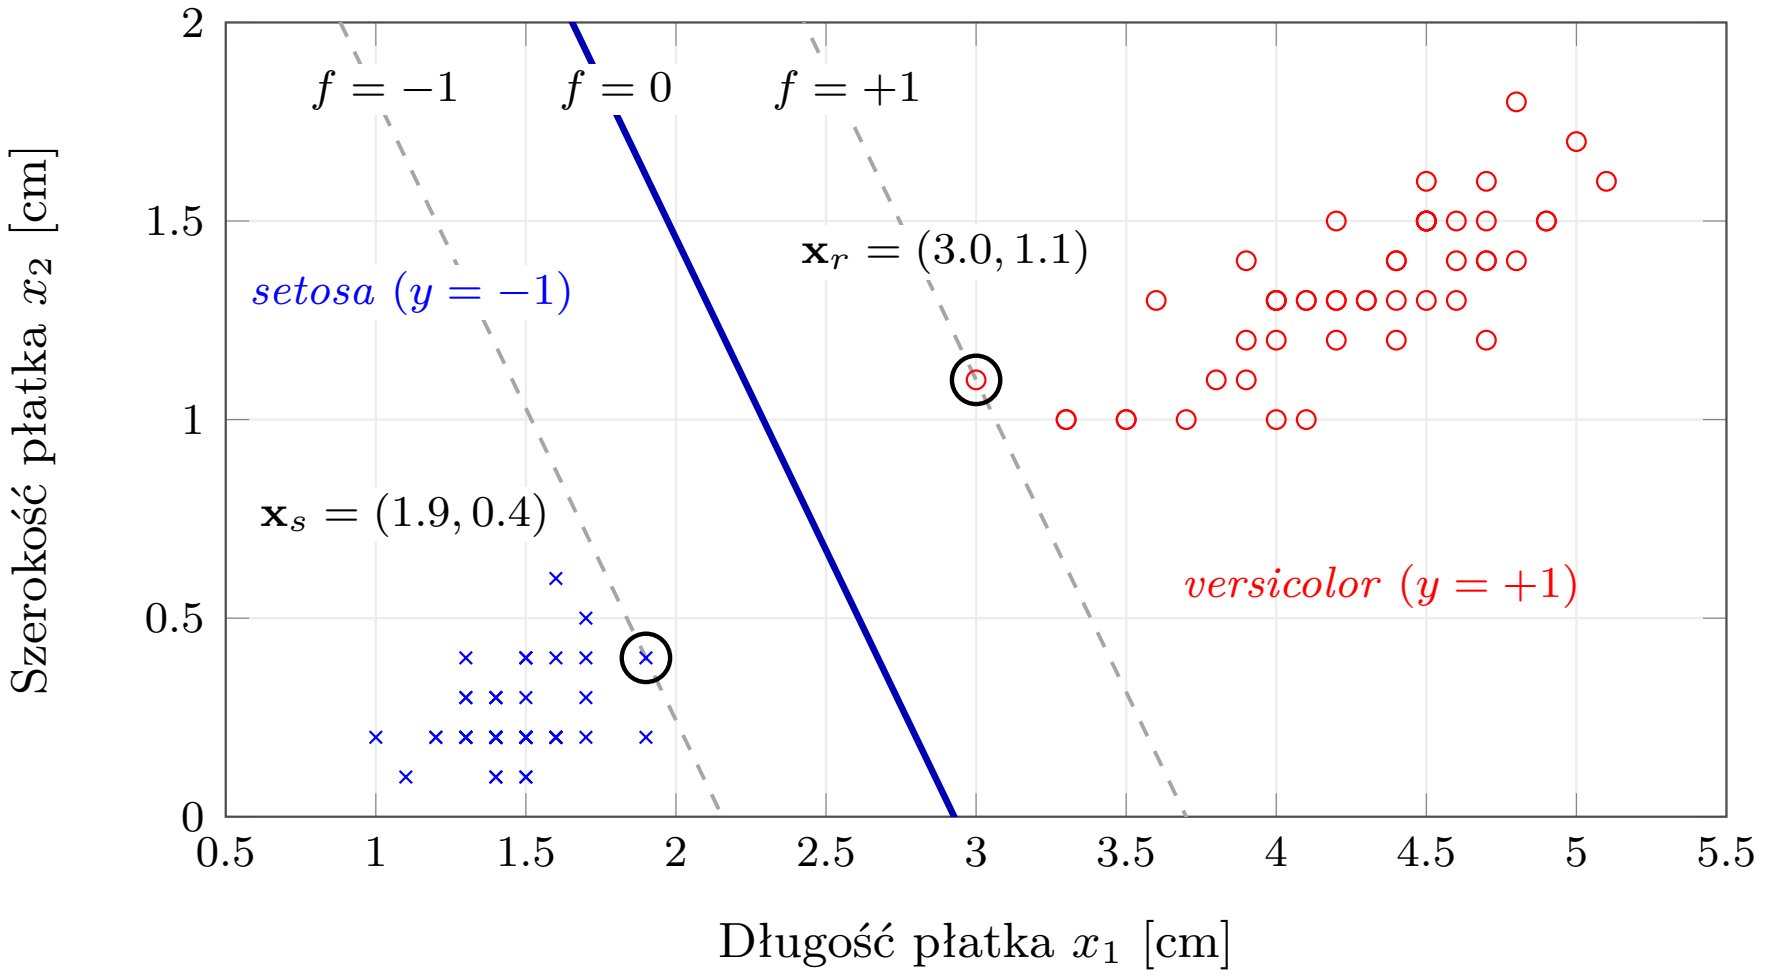
- długość działki kielicha,
- szerokość działki kielicha,
- długość płatka,
- szerokość płatka.

W przykładzie rozważane są tylko klasy *setosa* i *versicolor* oraz cechy długość płatka (x_1) i szerokość płatka (x_2):

$$\mathbf{x}_l = (x_{l1}, x_{l2}) \in \mathbb{R}^2, \qquad l = 1, \ldots, 100.$$

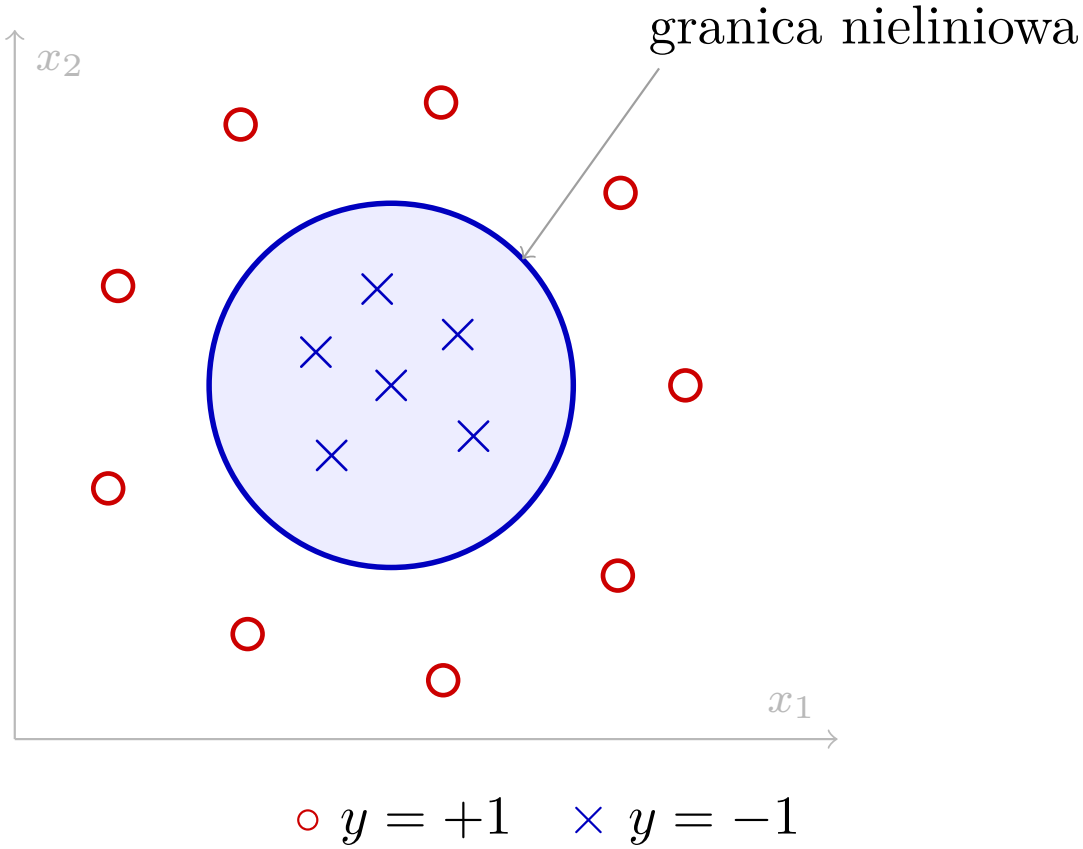
Przyjmujemy $y_l = -1$ dla klasy *setosa* oraz $y_l = +1$ dla klasy *versicolor*.

Przykład liniowej separowalności – rezultat



$$f(\mathbf{x}) = \frac{22}{17}x_1 + \frac{14}{17}x_2 - \frac{322}{85}, \qquad d = \frac{2}{\|\mathbf{w}^\star\|} = \sqrt{1.7}\,\text{cm} \approx 1.304\,\text{cm}.$$

Problem nieliniowo separowalny



Punkty klasy $+1$ otaczają punkty klasy -1. Żadna prosta nie oddzieli obu klas, ale rozdziela je pokazana granica nieliniowa.

Miękki margines w C-SVM

Dla danych liniowo nieseparowalnych warunku (3) nie można spełnić dla wszystkich punktów.

Rozwiązanie: wprowadzenie zmiennych $\xi_l \geqslant 0$, które dopuszczają naruszenie marginesu:

$$y_l \left(\mathbf{w} \cdot \mathbf{x}_l + b\right) \geqslant 1 - \xi_l, \qquad l = 1, \ldots, L. \tag{22}$$

Realizacja: wyznaczenie $\mathbf{w}$, b oraz $\boldsymbol{\xi}$, minimalizując funkcję celu (**problem podstawowy**):

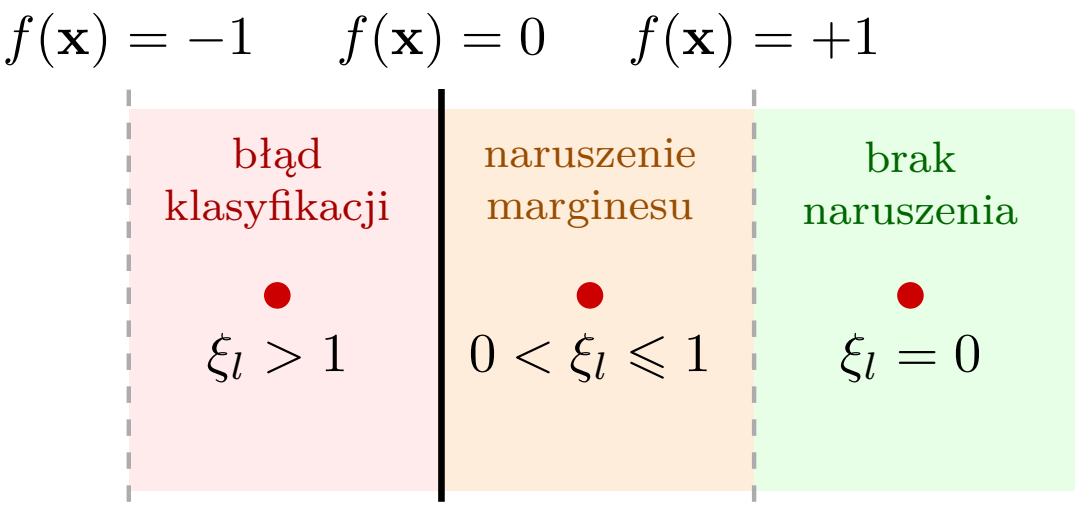
$$\Phi(\mathbf{w}, \boldsymbol{\xi}) = \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{l=1}^{L} \xi_l, \tag{23}$$

przy ograniczeniach (22) i $\xi_l \geqslant 0$.

Parametr $C > 0$ określa wagę kary za naruszenia marginesu.

Znaczenie zmiennych ξ_l

Dla punktów klasy $y_l = +1$ rozważamy położenie względem $f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b = 0$:



Błąd klasyfikacji także oznacza naruszenie marginesu.

Przy optymalnym ξ_l:

$$\xi_l = \max\{0,\ 1 - y_l f(\mathbf{x}_l)\}.$$

Na granicy decyzyjnej $f(\mathbf{x}_l) = 0$ mamy $\xi_l = 1$.

Lagrangian dla C-SVM

Rozwiązanie $\mathcal{L}$:

wprowadzenie nieujemnych mnożników Lagrange'a α_l i β_l dla dwóch ograniczeń z poprzedniego slajdu:

$$\begin{aligned}\mathcal{L}(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{l=1}^{L}\xi_l \\ - \sum_{l=1}^{L}\alpha_l\left[y_l(\mathbf{w}\cdot\mathbf{x}_l + b) - 1 + \xi_l\right] - \sum_{l=1}^{L}\beta_l\xi_l.\end{aligned} \tag{24}$$

Minimum po $\mathbf{w}$, b i $\boldsymbol{\xi}$ oraz maksimum po mnożnikach można sformułować jako jeden problem:

$$\max_{\boldsymbol{\alpha},\boldsymbol{\beta}} \min_{\mathbf{w},b,\boldsymbol{\xi}} \mathcal{L}(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \tag{25}$$

przy $\alpha_l, \beta_l \geqslant 0$ dla $l = 1, \ldots, L$.

Warunki KKT dla C-SVM

Pierwsze trzy równości wynikają z różniczkowania $\mathcal{L}$ po zmiennych $\mathbf{w}$, b i ξ_l:

$$\begin{cases} \nabla_{\mathbf{w}}\mathcal{L} = \mathbf{w} - \sum_{l=1}^{L} \alpha_l y_l \mathbf{x}_l = \mathbf{0}, \\ \dfrac{\partial \mathcal{L}}{\partial b} = -\sum_{l=1}^{L} \alpha_l y_l = 0, \\ \dfrac{\partial \mathcal{L}}{\partial \xi_l} = C - \alpha_l - \beta_l = 0, \\ y_l(\mathbf{w}\cdot\mathbf{x}_l + b) - 1 + \xi_l \geqslant 0, \qquad \xi_l \geqslant 0, \\ \alpha_l \geqslant 0, \qquad \beta_l \geqslant 0, \\ \alpha_l \left[y_l(\mathbf{w}\cdot\mathbf{x}_l + b) - 1 + \xi_l\right] = 0, \qquad \beta_l \xi_l = 0. \end{cases} \tag{26}$$

Wszystkie warunki z indeksem l obowiązują dla $l = 1, \ldots, L$.

Ostateczna postać problemu dualnego

Z równości $C - \alpha_l - \beta_l = 0$ oraz warunku $\alpha_l, \beta_l \geqslant 0$ wynika $0 \leqslant \alpha_l \leqslant C$.

Podstawiając $\mathbf{w} = \sum_{l=1}^{L} \alpha_l y_l \mathbf{x}_l$ oraz $\sum_{l=1}^{L} \alpha_l y_l = 0$ do (24):

$$W(\boldsymbol{\alpha}) = \sum_{l=1}^{L} \alpha_l - \frac{1}{2} \sum_{l=1}^{L} \sum_{k=1}^{L} \alpha_l \alpha_k y_l y_k (\mathbf{x}_l \cdot \mathbf{x}_k). \tag{27}$$

$$\max_{\boldsymbol{\alpha}} W(\boldsymbol{\alpha}) \quad \text{przy} \quad \begin{cases} 0 \leqslant \alpha_l \leqslant C, \quad l = 1, \ldots, L, \\ \sum_{l=1}^{L} \alpha_l y_l = 0. \end{cases} \tag{28}$$

W porównaniu z (16) pojawia się górne ograniczenie $\alpha_l \leqslant C$.

Parametr C określa kompromis między szerokością marginesu a karą za jego naruszenia.

Istotne uwagi

1. W problemie dualnym (28) dane występują w postaci iloczynów skalarnych $\mathbf{x}_l \cdot \mathbf{x}_k$.
2. Dla tych iloczynów funkcja decyzyjna ma postać:

$$f(\mathbf{x}) = \sum_{l=1}^{L} \alpha_l^\star y_l (\mathbf{x}_l \cdot \mathbf{x}) + b^\star = \mathbf{w}^\star \cdot \mathbf{x} + b^\star. \tag{29}$$

   Dla $\mathbf{w}^\star \neq \mathbf{0}$ granicą $f(\mathbf{x}) = 0$ jest hiperpłaszczyzna w przestrzeni wejściowej.
3. Zmienne ξ_l dopuszczają naruszenia marginesu i błędy klasyfikacji, lecz nie zmieniają postaci tej granicy.
4. Czym zastąpić iloczyn skalarny, aby uzyskać nieliniową granicę decyzyjną?

Odwzorowanie do przestrzeni cech

Gdy liniowa granica decyzyjna w $\mathbb{R}^I$ nie opisuje podziału klas, rozważane jest nieliniowe odwzorowanie do przestrzeni cech $\mathcal{F}$: $\boldsymbol{\Psi} : \mathbb{R}^I \to \mathcal{F}$.

Zgodnie z (Cortes, 1995), po odwzorowaniu danych do przestrzeni cech funkcja decyzyjna ma postać:

$$f(\mathbf{x}) = \mathbf{w} \cdot \boldsymbol{\Psi}(\mathbf{x}) + b.$$

Granica decyzyjna jest określona przez $f(\mathbf{x}) = 0$.

Po zastąpieniu $\mathbf{x}_l \cdot \mathbf{x}_k$ iloczynem $\boldsymbol{\Psi}(\mathbf{x}_l) \cdot \boldsymbol{\Psi}(\mathbf{x}_k)$ problem dualny ma postać:

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & \left\{ \sum_{l=1}^{L} \alpha_l - \frac{1}{2} \sum_{l=1}^{L} \sum_{k=1}^{L} \alpha_l \alpha_k y_l y_k \left(\boldsymbol{\Psi}(\mathbf{x}_l) \cdot \boldsymbol{\Psi}(\mathbf{x}_k) \right) \right\}, \\ \text{przy:} \quad & 0 \leqslant \alpha_l \leqslant C, \quad l = 1, \ldots, L, \\ & \sum_{l=1}^{L} \alpha_l y_l = 0. \end{aligned} \tag{30}$$

Przykład odwzorowania $\mathbf{\Psi}$

Dla $\mathbf{u} = [u_1, u_2]$ i $\mathbf{v} = [v_1, v_2]$ z $\mathbb{R}^2$ szukamy odwzorowania $\mathbf{\Psi} : \mathbb{R}^2 \to \mathbb{R}^6$, dla którego $\mathbf{\Psi}(\mathbf{u}) \cdot \mathbf{\Psi}(\mathbf{v}) = (\mathbf{u} \cdot \mathbf{v} + 1)^2$.

Rozwinięcie iloczynu:

$$\begin{aligned}(\mathbf{u} \cdot \mathbf{v} + 1)^2 &= (u_1 v_1 + u_2 v_2 + 1)^2 \\ &= u_1^2 v_1^2 + u_2^2 v_2^2 + 2u_1 u_2 v_1 v_2 + 2u_1 v_1 + 2u_2 v_2 + 1.\end{aligned}$$

Jedno z możliwych odwzorowań:

$$\mathbf{\Psi}(\mathbf{u}) = [u_1^2, u_2^2, \sqrt{2}u_1 u_2, \sqrt{2}u_1, \sqrt{2}u_2, 1],$$

$$\mathbf{\Psi}(\mathbf{v}) = [v_1^2, v_2^2, \sqrt{2}v_1 v_2, \sqrt{2}v_1, \sqrt{2}v_2, 1].$$

Równanie $\mathbf{w}_{\mathcal{F}} \cdot \mathbf{\Psi}(\mathbf{u}) + b = 0$ dla zmiennych u_1, u_2 ma postać:

$$w_1 u_1^2 + w_2 u_2^2 + \sqrt{2}w_3 u_1 u_2 + \sqrt{2}w_4 u_1 + \sqrt{2}w_5 u_2 + w_6 + b = 0.$$

W rozwiązaniu C-SVM: $w_6 = \sum_{l=1}^{L} \alpha_l y_l = 0$

Praktyczna realizacja odwzorowania do przestrzeni cech

W problemie dualnym potrzebujemy tylko iloczynów obrazów danych. Funkcja jądra pozwala obliczyć je bez jawnego wyznaczania $\mathbf{\Psi}$:

$$\mathcal{K}(\mathbf{u}, \mathbf{v}) = \mathbf{\Psi}(\mathbf{u}) \cdot \mathbf{\Psi}(\mathbf{v}). \tag{31}$$

Jeśli wybieramy $\mathcal{K}$ bez podawania $\mathbf{\Psi}$, musimy wiedzieć, czy odpowiada jej iloczyn w przestrzeni cech.

W klasycznej wersji twierdzenia Mercera dla ciągłej, symetrycznej $\mathcal{K}$ na zwartej dziedzinie $\Omega \subset \mathbb{R}^I$ sprawdzamy warunek:

$$\int_\Omega \int_\Omega \mathcal{K}(\mathbf{u}, \mathbf{v}) g(\mathbf{u}) g(\mathbf{v}) \, \mathrm{d}\mathbf{u} \, \mathrm{d}\mathbf{v} \geqslant 0, \qquad \forall g \in L^2(\Omega). \tag{32}$$

Wtedy (twierdzenie Mercera):

$$\mathcal{K}(\mathbf{u}, \mathbf{v}) = \sum_{m=1}^{\infty} \gamma_m \varphi_m(\mathbf{u}) \varphi_m(\mathbf{v}), \qquad \gamma_m \geqslant 0,$$

gdzie γ_m są wartościami własnymi, a φ_m funkcjami własnymi.

Przykłady funkcji jądra

Wybrane funkcje stosowane w SVM:

- jądro wielomianowe:

$$\mathcal{K}(\mathbf{u},\mathbf{v}) = (\mathbf{u}\cdot\mathbf{v}+1)^d, \qquad d = 2,3,\ldots, \tag{33}$$

- jądro Gaussowskie (RBF):

$$\mathcal{K}(\mathbf{u},\mathbf{v}) = \exp\left(-\frac{\|\mathbf{u}-\mathbf{v}\|^2}{2\sigma^2}\right), \qquad \sigma > 0, \tag{34}$$

- jądro wykładnicze (Laplace'a):

$$\mathcal{K}(\mathbf{u},\mathbf{v}) = \exp\left(-\frac{\|\mathbf{u}-\mathbf{v}\|}{\rho}\right), \qquad \rho > 0, \tag{35}$$

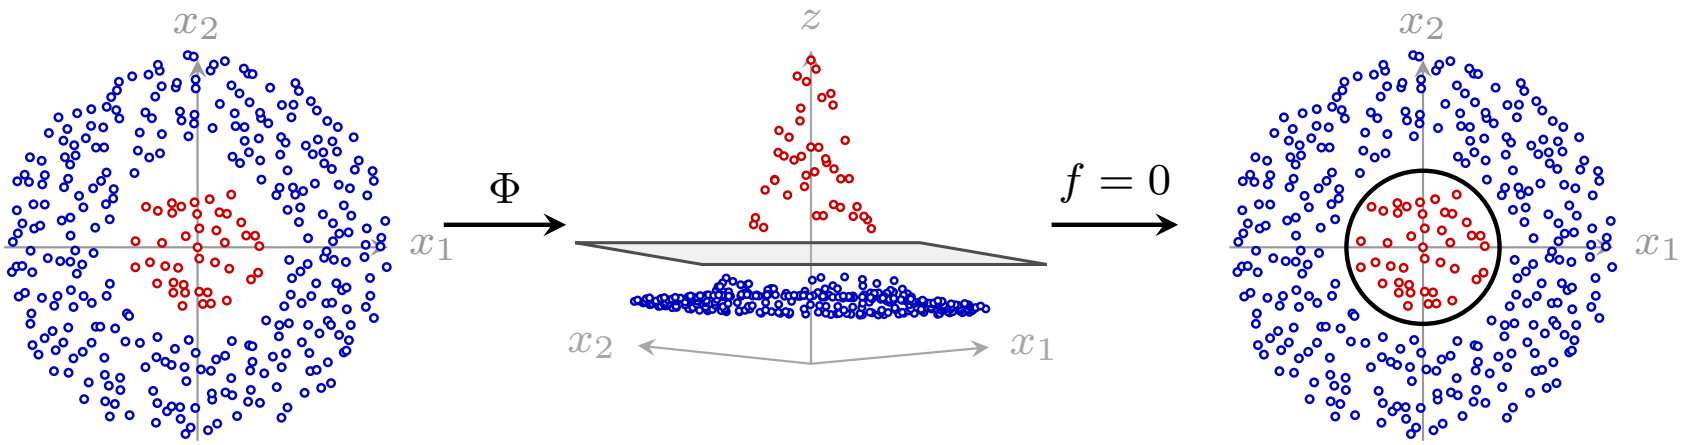
- funkcja sigmoidalna (typu MLP):

$$\mathcal{K}(\mathbf{u},\mathbf{v}) = \tanh\left(a\,\mathbf{u}\cdot\mathbf{v}+r\right), \qquad a > 0, \quad r \in \mathbb{R}. \tag{36}$$

Odwzorowanie do przestrzeni cech

Przykład: $\Phi(\mathbf{x}) = (x_1, x_2, g(\mathbf{x}))$, gdzie $g(\mathbf{x}) = \exp\left[-\frac{\|\mathbf{x}\|^2}{2\sigma^2}\right]$ oraz $\sigma = 1.4$.

dane w $\mathbb{R}^2$ | przestrzeń cech | granica w $\mathbb{R}^2$



brak prostej separującej | płaszczyzna $z = 0.21$ | $x_1^2 + x_2^2 = R^2$

$$f(\mathbf{x}) = g(\mathbf{x}) - 0.21 = 0 \iff x_1^2 + x_2^2 = R^2, \quad R = \sigma\sqrt{-2\ln(0.21)} \approx 2.47$$

Uogólniony problem dualny

Zastępując w (30) iloczyn skalarny w przestrzeni cech funkcją jądra $\mathcal{K}$, otrzymujemy:

$$W(\boldsymbol{\alpha}) = \sum_{l=1}^{L} \alpha_l - \frac{1}{2} \sum_{l=1}^{L} \sum_{k=1}^{L} \alpha_l \alpha_k y_l y_k \mathcal{K}(\mathbf{x}_l, \mathbf{x}_k).$$

Problem dualny C–SVM ma zatem postać:

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & W(\boldsymbol{\alpha}) \\ \text{przy warunkach} \quad & 0 \leqslant \alpha_l \leqslant C, \quad l = 1, \ldots, L, \\ & \sum_{l=1}^{L} \alpha_l y_l = 0. \end{aligned} \tag{37}$$

Wybór jądra $\mathcal{K}$ wpływa na postać granicy decyzyjnej, a parametr C ustala wagę naruszeń marginesu w problemie podstawowym.

Uogólniony optymalny klasyfikator

Niech:

- $\boldsymbol{\alpha}^\star$ będzie rozwiązaniem problemu (37),
- $SV = \{v : \alpha_v^\star > 0\}$ oznacza zbiór indeksów wektorów wspierających.

Funkcja decyzyjna i predykcja klasy dla C–SVM:

$$f(\mathbf{x}) = \sum_{v \in SV} \alpha_v^\star y_v \mathcal{K}(\mathbf{x}_v, \mathbf{x}) + b^\star, \qquad \widehat{y}(\mathbf{x}) = \operatorname{sign}\big(f(\mathbf{x})\big). \tag{38}$$

Wyznaczenie $b^\star$:

- po obliczeniu mnożników $\alpha^\star$ wybieramy dowolny wektor uczący, dla którego $0 < \alpha_l^\star < C$;
- leży on na brzegu marginesu, więc $f(\mathbf{x}_l) = y_l$;
- podstawiamy ten punkt do funkcji decyzyjnej i obliczamy $b^\star$.

Inne podejście: ν-SVM (Schölkopf et al., 2000)

Schölkopf, Smola, Williamson i Bartlett zaproponowali nowe rozwiązanie: algorytm ν-SVM.

Powód: parametr C wpływa na liczbę wektorów wspierających, ale nie określa wprost ich odsetka.

W ν–SVM stosuje się inną parametryzację: zamiast C występuje parametr ν oraz dodatkowa zmienna ρ, wyznaczana podczas uczenia.

- ν ustalane jest przed uczeniem: określa dolną granicę odsetka wektorów wspierających i górną granicę odsetka obserwacji naruszających margines.
- ρ wyznacza algorytm podczas uczenia: wraz z wektorem $\mathbf{w}$ określa szerokość marginesu: odległość między jego dwiema granicami wynosi $2\rho/\|\mathbf{w}\|$.

Problem podstawowy dla ν–SVM

W ν-SVM minimalizowany jest funkcjonał złożony z trzech składników:

- $\frac{1}{2}\|\mathbf{w}\|^2$: sprzyja mniejszej normie $\mathbf{w}$;
- $-\nu\rho$: sprzyja większej wartości ρ;
- $\frac{1}{L}\sum_{l=1}^{L}\xi_l$: ogranicza sumę naruszeń marginesu.

przy czym parametr ν określa wagę składnika $-\rho$.

Rozwiązywane jest zadanie:

$$\min_{\mathbf{w},b,\boldsymbol{\xi},\rho} \quad \Phi(\mathbf{w},\boldsymbol{\xi},\rho) = \frac{1}{2}\|\mathbf{w}\|^2 - \nu\rho + \frac{1}{L}\sum_{l=1}^{L}\xi_l, \tag{39}$$

przy ograniczeniach:

$$\begin{aligned} y_l\big(\mathbf{w}\cdot\mathbf{x}_l + b\big) &\geqslant \rho - \xi_l, \qquad \xi_l \geqslant 0 \quad (l = 1,\ldots,L), \\ \rho &\geqslant 0. \end{aligned} \tag{40}$$

Lagrangian dla ν–SVM

Przyjmując zgodnie z założeniami $\alpha_l, \beta_l, \delta \geqslant 0$:

$$\begin{aligned}\mathcal{L} = \frac{1}{2}\|\mathbf{w}\|^2 - \nu\rho + \frac{1}{L}\sum_{l=1}^{L}\xi_l \\ - \sum_{l=1}^{L}\alpha_l\left[y_l(\mathbf{w}\cdot\mathbf{x}_l + b) - \rho + \xi_l\right] - \sum_{l=1}^{L}\beta_l\xi_l - \delta\rho\end{aligned} \tag{41}$$

oraz zerując pochodne $\mathcal{L}$ względem $\mathbf{w}$, b, $\boldsymbol{\xi}$ i ρ, otrzymujemy:

$$\mathbf{w} = \sum_{l=1}^{L}\alpha_l y_l \mathbf{x}_l, \tag{42}$$

$$\alpha_l + \beta_l = \frac{1}{L}, \qquad \sum_{l=1}^{L}\alpha_l y_l = 0, \qquad \sum_{l=1}^{L}\alpha_l - \delta = \nu. \tag{43}$$

Problem dualny dla ν–SVM

Podstawiając (42) i (43) do Lagrangianu (41) oraz zastępując iloczyn skalarny funkcją jądra:

$$\max_{\boldsymbol{\alpha}} W(\boldsymbol{\alpha}), \qquad W(\boldsymbol{\alpha}) = -\frac{1}{2}\sum_{l=1}^{L}\sum_{k=1}^{L}\alpha_l\alpha_k y_l y_k \mathcal{K}(\mathbf{x}_l, \mathbf{x}_k), \tag{44}$$

przy ograniczeniach:

$$0 \leqslant \alpha_l \leqslant \frac{1}{L} \quad (l = 1, \ldots, L), \qquad \sum_{l=1}^{L}\alpha_l y_l = 0, \qquad \sum_{l=1}^{L}\alpha_l \geqslant \nu.$$

W porównaniu z C-SVM:

- znika składnik $\sum_l \alpha_l$ z funkcji celu;
- ograniczenie $\alpha_l \leqslant C$ zostaje zastąpione przez $\alpha_l \leqslant 1/L$;
- pojawia się ograniczenie $\sum_l \alpha_l \geqslant \nu$.

Optymalny klasyfikator ν–SVM

Wektory z $\alpha_l^\star > 0$ tworzą zbiór SV. Funkcja decyzyjna ma postać:

$$\begin{aligned} f(\mathbf{x}) &= \sum_{v \in SV} \alpha_v^\star y_v \mathcal{K}(\mathbf{x}_v, \mathbf{x}) + b^\star, \\ \widehat{y}(\mathbf{x}) &= \operatorname{sign}\big(f(\mathbf{x})\big). \end{aligned} \tag{45}$$

Niech S_+ i S_- zawierają po $s > 0$ wektorów z klas $+1$ i -1, dla których $0 < \alpha_l^\star < 1/L$. Wówczas:

$$b^\star = -\frac{1}{2s} \sum_{\mathbf{x} \in S_+ \cup S_-} \sum_{l=1}^{L} \alpha_l^\star y_l \mathcal{K}(\mathbf{x}_l, \mathbf{x}). \tag{46}$$

Jeżeli $\rho^\star > 0$, to $\sum_l \alpha_l^\star = \nu$. Wynikają stąd dwa wnioski:

- liczba wektorów wspierających wynosi co najmniej νL;
- co najwyżej νL obserwacji ma $\alpha_l^\star = 1/L$; wszystkie obserwacje z $\xi_l^\star > 0$ należą do tej grupy.

Algorytm SVM w klasyfikacji jednoklasowej

Klasyfikator jednoklasowy uczony jest na przykładach jednej klasy.

Dla nowej obserwacji rozstrzyga on, czy należy ona do obszaru wyznaczonego przez te przykłady.

Podejście to wiąże się z:

- wykrywaniem obserwacji odstających (ang. *outlier detection*),
- wykrywaniem anomalii (ang. *anomaly detection*),
- detekcją nowości (ang. *novelty detection*).

W pracy (Schölkopf et al., 2001) zaproponowano wersję SVM do tego zadania: OC-SVM (ang. *one-class SVM*).

Podczas uczenia nie korzysta się z etykiet dwóch klas.

OC-SVM: idea metody

Cel: wyznaczyć obszar S zawierający większość obserwacji uczących.

Strategia: odwzorować dane przez $\mathbf{\Psi}$ do przestrzeni cech i oddzielić ich obrazy od początku układu hiperpłaszczyzną $\mathbf{w} \cdot \mathbf{z} = \rho$.

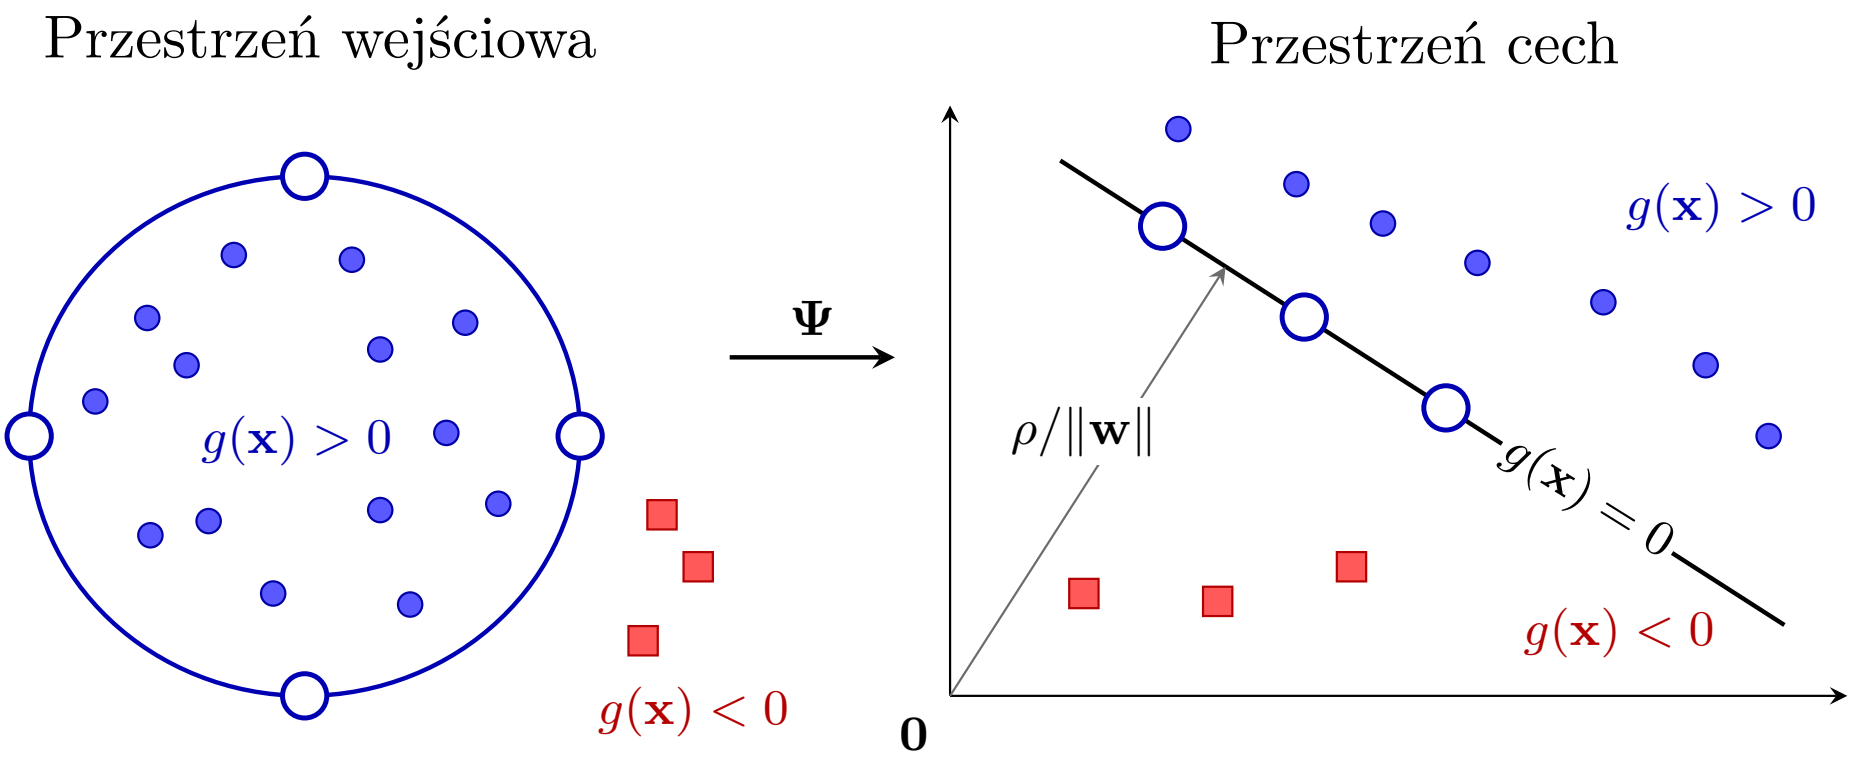
Dopuszcza się naruszenie tego warunku przez część obserwacji.

Decyzja: dla nowej obserwacji obliczyć

$$g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{\Psi}(\mathbf{x}) - \rho.$$

- Jeżeli $g(\mathbf{x}) > 0$, obserwacja zostaje przyjęta; jeżeli $g(\mathbf{x}) < 0$, zostaje odrzucona.
- Równość $g(\mathbf{x}) = 0$ wyznacza granicę obszaru S.
- Przy $\rho > 0$ i $\mathbf{w} \neq \mathbf{0}$ odległość hiperpłaszczyzny od początku układu współrzędnych wynosi $\rho / \|\mathbf{w}\|$.

OC-SVM: ilustracja graficzna



• – dane uczące, ◯ – wektory wspierające, ■ – nowe obserwacje odrzucone.

OC-SVM: problem podstawowy

Minimalizacja funkcjonału:

$$\min_{\mathbf{w},\boldsymbol{\xi},\rho} \quad \Phi(\mathbf{w},\boldsymbol{\xi},\rho) = \frac{1}{2}\|\mathbf{w}\|^2 + \frac{1}{\nu L}\sum_{l=1}^{L}\xi_l - \rho, \tag{47}$$

przy ograniczeniach dla $l = 1, \ldots, L$:

$$\mathbf{w}\cdot\boldsymbol{\Psi}(\mathbf{x}_l) \geqslant \rho - \xi_l, \qquad \xi_l \geqslant 0. \tag{48}$$

gdzie $\boldsymbol{\Psi} : \mathbb{R}^I \to \mathcal{F}$ odwzorowuje dane do przestrzeni cech, a $\rho \in \mathbb{R}$.

Jeżeli $\rho^\star \neq 0$, parametr $\nu \in (0, 1)$ ma następującą interpretację:

- liczba odrzuconych obserwacji uczących nie przekracza νL,
- liczba wektorów wspierających wynosi co najmniej νL.

Problem dualny i funkcja decyzyjna

Po wprowadzeniu mnożników Lagrange'a otrzymujemy:

$$\max_{\boldsymbol{\alpha}} W(\boldsymbol{\alpha}), \qquad W(\boldsymbol{\alpha}) = -\frac{1}{2}\sum_{l,k=1}^{L} \alpha_l \alpha_k \mathcal{K}(\mathbf{x}_l, \mathbf{x}_k). \tag{49}$$

przy ograniczeniach:

$$0 \leqslant \alpha_l \leqslant \frac{1}{\nu L} \quad (l = 1, \ldots, L), \qquad \sum_{l=1}^{L} \alpha_l = 1.$$

Rozwiązanie $\boldsymbol{\alpha}^\star$ i próg $\rho^\star$ wyznaczają funkcję decyzyjną:

$$\begin{aligned} g(\mathbf{x}) &= \sum_{l=1}^{L} \alpha_l^\star \mathcal{K}(\mathbf{x}_l, \mathbf{x}) - \rho^\star, \\ \widehat{y}(\mathbf{x}) &= \operatorname{sign}\big(g(\mathbf{x})\big). \end{aligned} \tag{50}$$

Jeżeli istnieje indeks j, dla którego $0 < \alpha_j^\star < 1/(\nu L)$, to warunki KKT dają:

$$\rho^\star = \sum_{l=1}^{L} \alpha_l^\star \mathcal{K}(\mathbf{x}_l, \mathbf{x}_j).$$

SVM w klasyfikacji wieloklasowej

Dotychczasowe klasyfikatory (19) i (38) przypisują obserwacji jedną z dwóch etykiet: -1 albo $+1$.

Klasyfikatory są więc modelami binarnymi; wartości -1 i $+1$ stanowią bipolarne kodowanie etykiet klas.

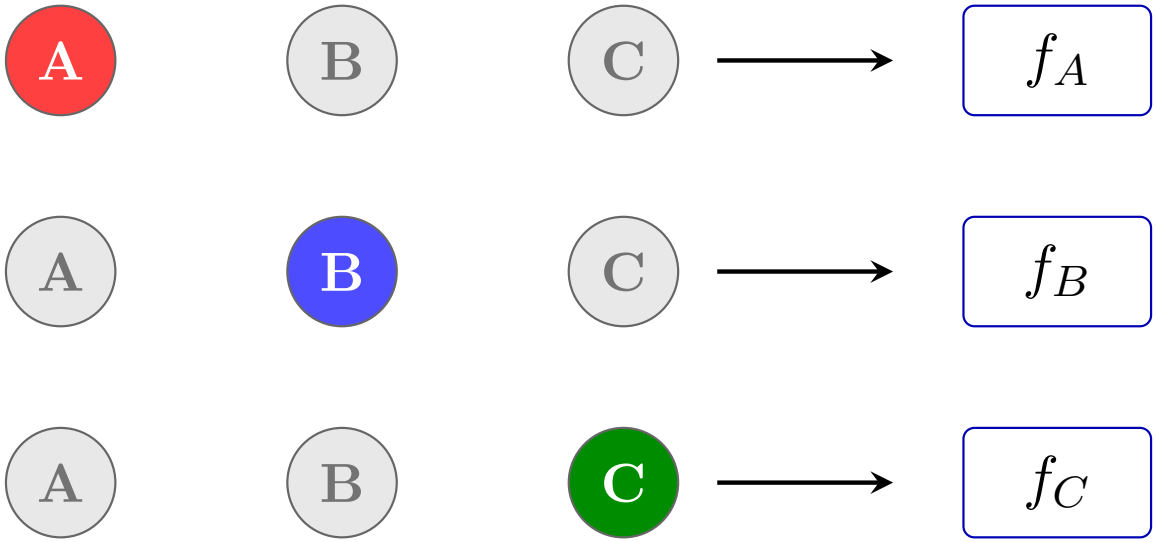
Dla $K > 2$ klas można połączyć wyniki kilku klasyfikatorów binarnych:

- **jeden przeciwko reszcie** (ang. *one against all*),
- **jeden przeciwko jednemu** (ang. *one against one*).

Można także uczyć wszystkie klasy wspólnie w jednym problemie optymalizacyjnym (Weston i Watkins, 1998).

Jeden przeciwko reszcie

Każdej klasie odpowiada osobny klasyfikator binarny. Jej obserwacje otrzymują etykietę $+1$, a obserwacje pozostałych klas etykietę -1.



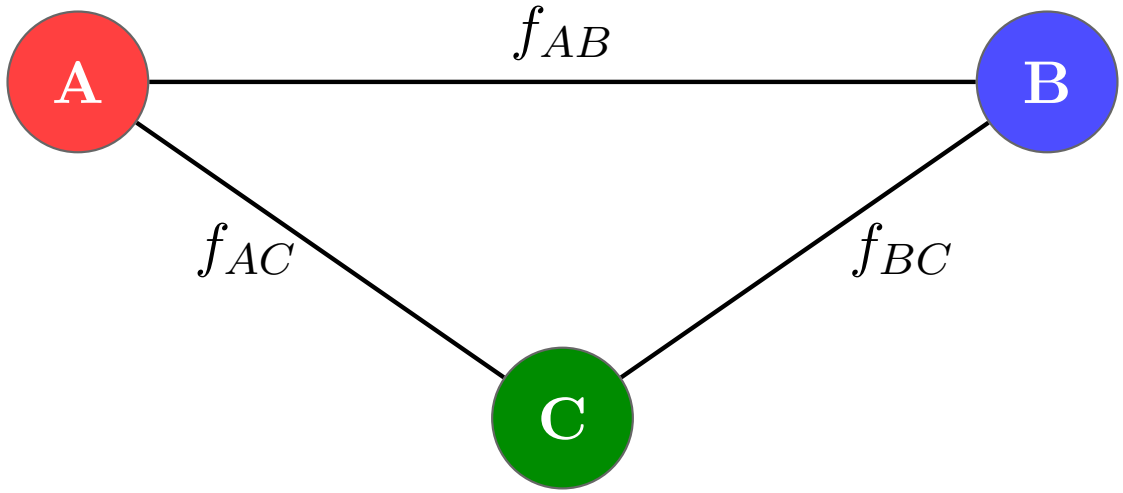
Dla K klas powstaje K funkcji decyzyjnych f_k.

Obserwację przypisujemy klasie, dla której wartość $f_k(\mathbf{x})$ jest największa:

$$\widehat{y}(\mathbf{x}) = \underset{k\in\{1,\ldots,K\}}{\operatorname{argmax}} \; f_k(\mathbf{x}).$$

Jeden przeciwko jednemu

Osobny klasyfikator uczymy dla każdej pary klas, korzystając tylko z obserwacji należących do tej pary.

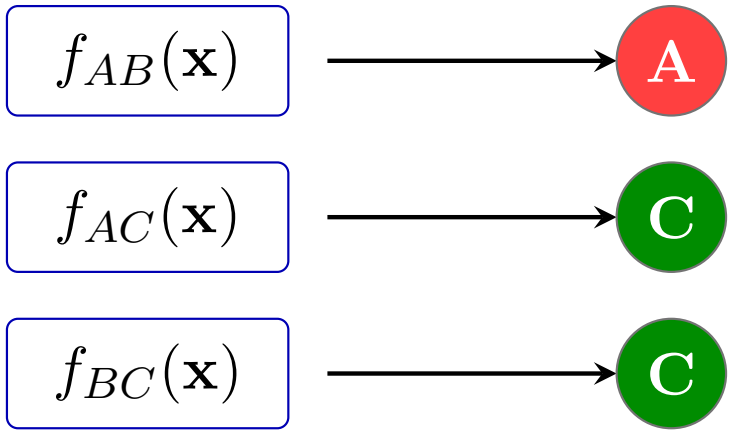


Dla K klas liczba binarnych zadań klasyfikacji wynosi:

$$\binom{K}{2} = \frac{K(K-1)}{2}.$$

Głosowanie w metodzie jeden przeciwko jednemu

Wynik każdego klasyfikatora stanowi jeden głos. Przykład dla trzech klas i obserwacji $\mathbf{x}$:



Klasa C otrzymała dwa głosy, a klasa A jeden. Ogólnie:

$$\widehat{y}(\mathbf{x}) = \underset{k\in\{1,\ldots,K\}}{\operatorname{argmax}} \; V_k(\mathbf{x}),$$

gdzie $V_k(\mathbf{x})$ oznacza liczbę głosów oddanych na klasę k.

Gdy kilka klas uzyska tę samą największą liczbę głosów, wybieramy pierwszą z nich w ustalonej kolejności klas (Hsu i Lin, 2002).

Prawdopodobieństwo klasyfikacji

Po wyuczeniu SVM etykietę klasy wyznacza się ze znaku funkcji decyzyjnej:

$$\widehat{y}(\mathbf{x}) = \operatorname{sign}\big(f(\mathbf{x})\big), \qquad f(\mathbf{x}) = \sum_{v \in SV} \alpha_v^\star y_v \mathcal{K}(\mathbf{x}_v, \mathbf{x}) + b^\star. \tag{51}$$

Wartość $f(\mathbf{x})$ nie jest prawdopodobieństwem przynależności do klasy.

W wielu zastosowaniach potrzebne jest oszacowanie $\Pr(y = +1 \mid \mathbf{x})$.

Platt zaproponował dopasowanie do wyników SVM funkcji sigmoidalnej (Platt, 2000):

$$\Pr(y = +1 \mid \mathbf{x}) \approx P_{A,B}\big(f(\mathbf{x})\big) = \frac{1}{1 + \exp\big(Af(\mathbf{x}) + B\big)}. \tag{52}$$

Parametry A i B wyznacza się w oddzielnym etapie po uczeniu SVM.

Prawdopodobieństwo klasyfikacji – kalibracja

1. **Wyznacz wyniki SVM**
   Dla każdej obserwacji zapisz wynik f_l oraz jej rzeczywistą etykietę y_l. Wartości f_l można uzyskać w walidacji krzyżowej.

2. **Ustal wartości docelowe**
   Dla N_+ obserwacji klasy dodatniej i N_- klasy ujemnej przyjmij wygładzone wartości:

$$t_l = \begin{cases} \dfrac{N_+ + 1}{N_+ + 2}, & y_l = +1, \\ \dfrac{1}{N_- + 2}, & y_l = -1. \end{cases} \tag{53}$$

3. **Dopasuj sigmoidę**
   Zdefiniuj p_l zgodnie z (52) i zminimalizuj ujemny logarytm wiarygodności:

$$(A^\star, B^\star) = \underset{A,B}{\operatorname{argmin}} \left\{ -\sum_{l=1}^{L} \left[t_l \log p_l + (1 - t_l) \log(1 - p_l) \right] \right\}. \tag{54}$$

Implementacje algorytmu SVM

Problemy dualne C–SVM i ν–SVM mają postać zadań programowania kwadratowego (QP).

Wśród klasycznych metod stosowanych w tym celu są:

- *chunking* (Vapnik, 2006),
- metoda dekompozycji Osuny (Osuna et al., 1997),
- sekwencyjna minimalna optymalizacja (SMO) (Platt, 1998).

Przykładowe implementacje i narzędzia:

- SVM^{light} (Joachims, 1998) oraz LIBSVM,
- MATLAB: `fitcsvm` do klasyfikacji i `fitrsvm` do regresji,
- Python: `scikit-learn` (`SVC`, `NuSVC`, `OneClassSVM`, `SVR`),
- `quadprog` w MATLAB-ie do rozwiązania jawnie sformułowanego zadania QP,
- Statistica, IBM SPSS Modeler oraz DTREG.

Sequential Minimal Optimization

Algorytm SMO (ang. *sequential minimal optimization*) zaproponował John Platt w 1998 roku (Platt, 1998).

Służy on do rozwiązania dualnego problemu QP, dla C-SVM w (37).

W kolejnych iteracjach SMO:

- wybiera dwa mnożniki Lagrange'a, pozostawiając pozostałe bez zmian,
- wyznacza dla tej pary nowe wartości z zachowaniem ograniczeń problemu dualnego,
- powtarza kroki, aż warunki KKT są spełnione z przyjętą tolerancją.

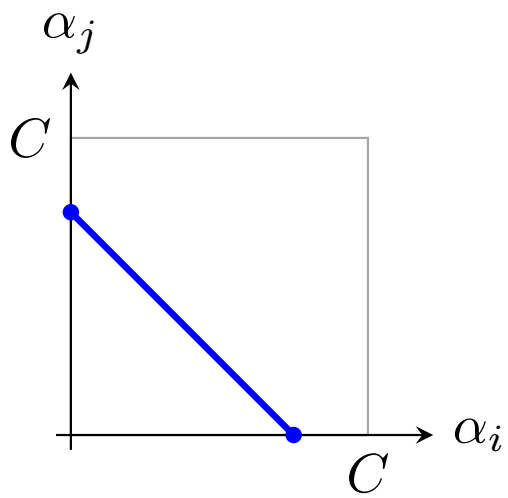
Podproblem z dwoma mnożnikami można rozwiązać analitycznie, bez wywoływania ogólnego algorytmu QP w każdej iteracji.

SMO - ograniczenia dla dwóch mnożników

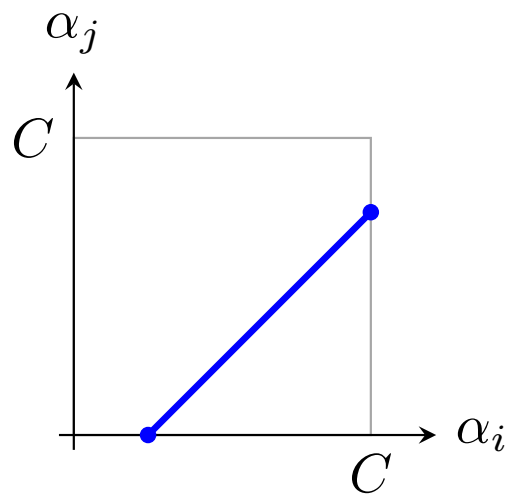
Przy ustalonych pozostałych mnożnikach warunek $\sum_{l=1}^{L} \alpha_l y_l = 0$ ma postać:

$$y_i \alpha_i + y_j \alpha_j = r, \qquad r = - \sum_{l \notin \{i,j\}} \alpha_l y_l.$$

Ponadto $0 \leqslant \alpha_i, \alpha_j \leqslant C$.



$y_i = y_j : \ \alpha_i + \alpha_j = \text{const}$



$y_i \neq y_j : \ \alpha_i - \alpha_j = \text{const}$

Dopuszczalne wartości pary tworzą odcinek wewnątrz kwadratu $[0, C]^2$.

! SMO maksymalizuje funkcję W na tym odcinku.

SMO - jeden krok algorytmu

1. **Wybór pary.** Wybieramy obserwację naruszającą warunki KKT. Drugą dobieramy heurystycznie, szukając dużej różnicy $|E_i - E_j|$, gdzie $E_l = f(\mathbf{x}_l) - y_l$.
2. **Optymalizacja pary.** Z bieżących wartości mnożników i etykiet obliczamy granice L, H dopuszczalnych wartości α_j. Wyznaczamy nową wartość α_j w przedziale $[L, H]$, a następnie α_i z warunku $\sum_l \alpha_l y_l = 0$.
3. **Aktualizacja modelu.** Po zmianie mnożników aktualizujemy próg b i pamięć wartości E_l, wykorzystywaną przy wyborze kolejnej pary.

Te kroki powtarzamy do spełnienia warunków KKT z przyjętą tolerancją.

SVC w scikit-learn wykorzystuje LIBSVM, w którym zastosowano metodę typu SMO.

Zastosowania idei wektorów wspierających

Metody oparte na idei wektorów wspierających obejmują:

- **klasyfikację binarną**: C-SVM i ν-SVM;
- **klasyfikację wieloklasową**: m.in. przez połączenie klasyfikatorów binarnych;
- **klasyfikację jednoklasową**: identyfikację obserwacji odmiennych lub nowych (OC-SVM);
- **regresję**: przewidywanie wartości liczbowych z uwzględnieniem tolerancji błędu (SVR);
- **klasteryzację**: wyznaczanie skupień danych bez etykiet na podstawie granic opisujących ich rozkład (support vector clustering).

Literatura I

Vapnik V.N. (1995) The Nature of Statistical Learning Theory. Springer-Verlag, New York

Vapnik, V.N., Chervonenkis, A.Y. (1971) On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities. Theory of Probability & Its Applications 16(2), s. 264

Drucker H., Burges C., Kaufman L., Smola A.J., Vapnik V (1997) Support Vector Regression Machines. Advances in Neural Information Processing Systems 9, NIPS 1997, s. 155–161, MIT Press

Vapnik V. (2006) Estimation of dependences based on empirical data. Springer-Verlag Berlin, Heidelberg

Osuna E., Freund R., Girosi F. (1997) Improved Training Algorithm for Support Vector Machines, Proceedings of Neural Networks for Signal Processing Workshop

Joachims T. (1998) Making Large-Scale SVM Learning Practical. Advances in Kernel Methods - Support Vector Learning. Red. B. Schölkopf, C.J.C. Burges i A.J. Smola, The MIT Press, Cambridge

Literatura II

Cortes C. Vapnik V. (1995) Support-Vector Networks. Machine Leaming 20, s. 273–297

Platt J.C. (1998) A Fast Algorithm for Training Support Vector Machines. Technical Report MSR-TR-98-14

Platt J.C. (2000) Probabilistic outputs for support vector machines and comparison to regularized likelihood methods. Advances in Large Margin Classifiers. Red. A. Smola, P. Bartlett, B. Schölkopf, and D. Schuurmans, MIT Press, Cambridge

Schölkopf B., Smola A.J., Williamson R.C., Bartlett P.L. (2000) New support vector algorithms. Neural Computation 12(5), s. 1207–1245

Schölkopf B., Platt J., Shawe-Taylor J., Smola A.J., Williamson R.C. (2001) Estimating the Support of High Dimensional Distribution. Neural Computation 13(7), s. 1443–1471

Weston J., Watkins C. (1998) Multi–class Support Vector Machines. Technical Report CSD-TR-98-04

Hsu C.-W., Lin C.-J. (2002). A comparison of methods for multiclass support vector machines. *IEEE Transactions on Neural Networks*, 13(2), 415–425.